@Odemir Depieri Jr

Prevendo índice Feminicídio

com Arima e WebScraping

statsmodels

scikit learn

plotly

pandas

matplotlib

Arima

ARIMA

Em estatística, particularmente em **análise de séries temporais**, um modelo auto-regressivo integrado de médias móveis é uma generalização de um modelo auto-regressivo de médias móveis (**ARMA**). Ambos os modelos **são ajustados aos dados da série temporal para entender melhor os dados** ou para prever pontos futuros na série. Modelos **ARIMA** são aplicados em alguns casos em que os dados mostram evidências de não estacionariedade, em que um passo inicial de diferenciação (correspondente à parte "integrada" do modelo) pode ser aplicado uma ou mais vezes para eliminar a não estacionariedade.

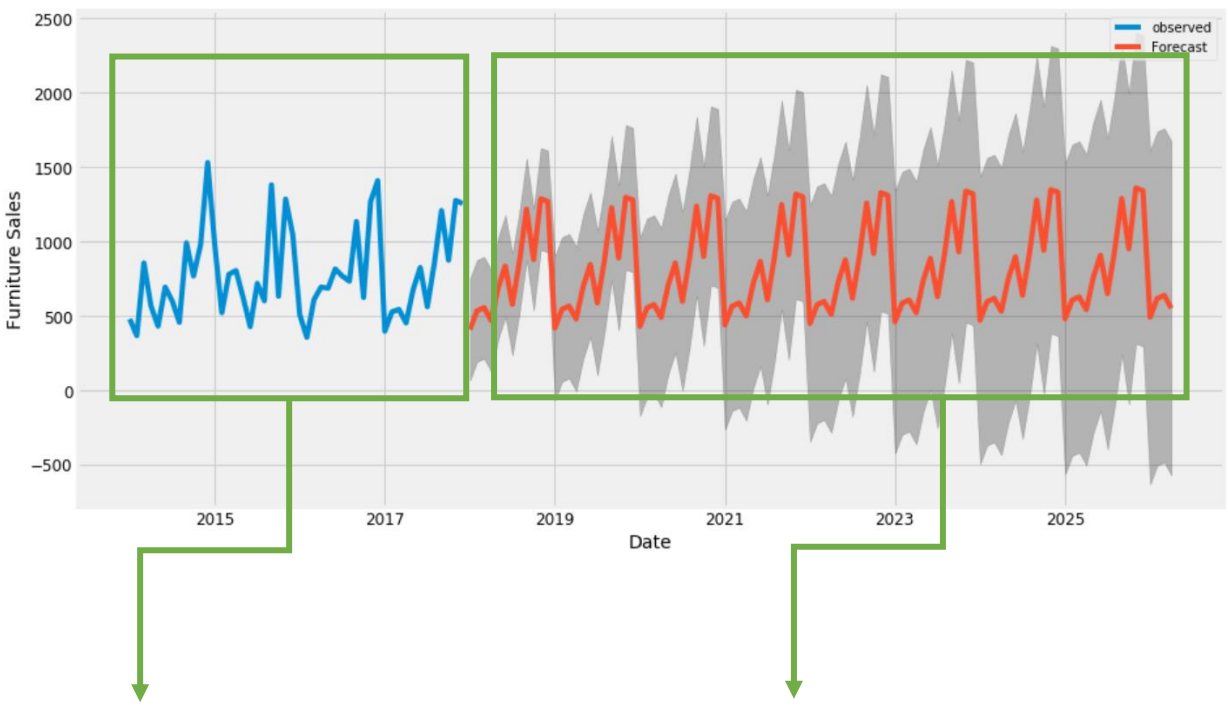

Dados Realizados
(Observação)

Previsão
(Forecast)

Artigos para leitura

https://www.machinelearningplus.com/time-series/arima-model-time-series-forecasting-python/

Vídeos

https://www.youtube.com/watch?v=v7rZpT8NCbk

Nesse case vamos extrair os dados do Governo do Estado de São Paulo

Vamos importar as bibliotecas

```
[52] # Instalando a lib para o autoarimma
     pip install pmdarima
```

```
[28] # Request é uma lib usada para request https
     import requests

     # Soup é a lib usada para scraping
     from bs4 import BeautifulSoup

     # Lib para modelagem de Dados
     import pandas as pd

     # Biblioteca para recursos de Data
     import datetime
     from dateutil.relativedelta import relativedelta

     # Lib para visualização gráfica
     import plotly.graph_objects as Dash

     # Bibliotecas de plotagem de dados
     import seaborn as sns
     import matplotlib.pyplot as plt
```

Vamos coletar os dados do Site

```
[29] # Carregando a pagina

     # Salvar o link da pagina
     Site = 'http://www.ssp.sp.gov.br/Estatistica/ViolenciaMulher.aspx'

     # Fazendo o carregando da pagina atraves do Request
     Pagina = requests.get(Site)
```

```
[30] # Coletando as infos do request e passar para o Soup os dados
     Coleta = BeautifulSoup(Pagina.text, 'html.parser')
```

```
[31] # Coletando o titulo da Pagina
     print( Coleta.title )
```

```
<title>
        SSP
</title>
```

```
[32] # Colando informações das Tabelas
     Tabelas = Coleta.find_all('table', attrs={'class':'table table-striped table-hover table-condensed'})

     # Verificando as Tabelas localizadas
     print( 'Localizado:', len(Tabelas), 'tabelas' )
```

```
Localizado: 119 tabelas
```

Vamos fazer o tratamento dos dados e extração dos textos

```
[33] # Lista para salvar os dados
     Rotulos = []
     Dados = []
     Periodos = []

     # Qual o utlimo registro da Tabela
     Registro_Inicial = datetime.datetime(2021, 7, 1)

     # Variavel para somar pular os meses
     Loop = 0

     # Loop para filtrar as informações
     for Consulta in Tabelas:

       # Filtrar a Linha da Tabela
       Linha = Consulta.find_all('tr')[2]

       # Filtrar o rotulo da Tabela
       Rotulo = Linha.find_all('td')[0].text

       # Filtrar a informação Geral
       Informação = Linha.find_all('span')[0].text

       # Calculando a data de registro
       Data = Registro_Inicial - relativedelta(months=Loop)
```

Continuação do script

```
    # Caso o conteudo seja Feminicidio
    if Rotulo == 'FEMINICÍDIO':
      Rotulos.append( Rotulo )
      Dados.append( Informação )
      Periodos.append( Data )

    # Ignorando caso seja diferente
    else:
      pass

    # Somando o Loop para dar o Desagiu no Mes
    Loop = Loop + 1

# Organizando em um Dicionario os Dados
Dicionario = {
    'Rotulo' : Rotulos,
    'Quantidade' : Dados,
    'Periodo' : Periodos
}

# Passando o dicionario como base de dados
Base_Feminicídio = pd.DataFrame( Dicionario )

# Verificando as primeiras Linhas
Base_Feminicídio.head()
```

	Rotulo	Quantidade	Periodo
0	FEMINICÍDIO	8	2021-07-01
1	FEMINICÍDIO	7	2021-06-01
2	FEMINICÍDIO	26	2021-05-01
3	FEMINICÍDIO	10	2021-04-01
4	FEMINICÍDIO	21	2021-03-01

Vamos preparar os dados para a serie

```
[34] # Definir a coluna Data como Index do DataSet
     Base_Feminicídio = Base_Feminicídio.set_index('Periodo')

     # Ordenar a Data
     Base_Feminicídio = Base_Feminicídio.sort_values(by='Periodo')
```

```
[35] # Verificando tipo das colunas
     Base_Feminicídio.info()
```

```
<class 'pandas.core.frame.DataFrame'>
DatetimeIndex: 43 entries, 2018-01-01 to 2021-07-01
Data columns (total 2 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   Rotulo      43 non-null     object
 1   Quantidade  43 non-null     object
dtypes: object(2)
memory usage: 1.0+ KB
```

```
[36] # Convertendo a coluna para inteiro
     Base_Feminicídio['Quantidade'] = pd.to_numeric( Base_Feminicídio['Quantidade'] )
```

Plotar o histórico

```
[37] # Criando um Gráfico Dinâmico
     # No gráfico é possivel filtrar pela legenda a informação
     # Utlizar zoons

     # Definindo uma figura
     Figura = Dash.Figure()

     # Incluindo o Eixo no Gráfico - Abertura
     Figura.add_trace(Dash.Scatter(x = Base_Feminicídio.index, y = Base_Feminicídio.Quantidade,
                         mode='lines',
                         name='Quantidade',
                         marker_color = '#FF7F0E',))

     # Modificando o Layout do Gráfico
     Figura.update_layout(
         title='Histórico de Feminicídio - Estado de São Paulo', # Titulo
         titlefont_size = 28, # Tamanho da Fonte

         # Parametros para mexer no eixo X
         xaxis = dict(
             title='Período Histórico', # Titulo do Eixo x
             titlefont_size=16, # Tamanho fonte do Titulo
             tickfont_size=14), # Tamanho da fonte do eixo

         # Tamanho do Grafico
         height = 500,
```

Continuação do script

```
    # Parametros para mexer no eixo y
    yaxis=dict(
        title='Quantidade', # Titulo do Eixo y
        titlefont_size=16, # Tamanho fonte do Titulo
        tickfont_size=14), # Tamanho da fonte do eixo

    # Parametros para mexer na legenda
    legend=dict(
        y=1, x=1, # Posição da Legenda
        bgcolor='rgba(255, 255, 255, 0)', # Cor de fundo
        bordercolor='rgba(255, 255, 255, 0)')) # Cor da Bornda

# Mostrando o Gráfico
Figura.show()
```

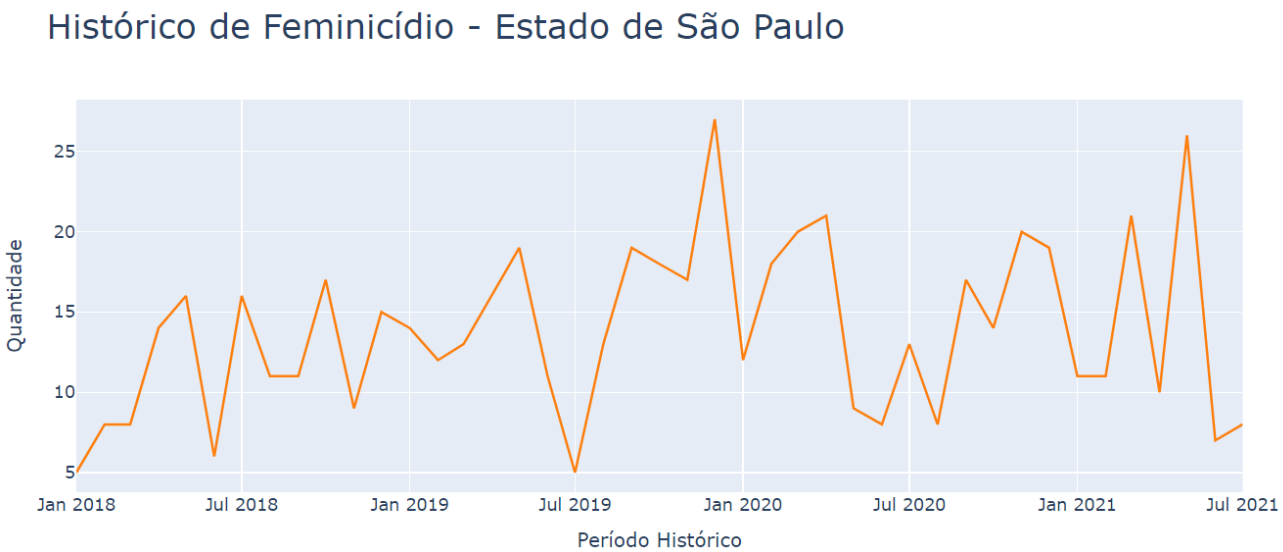

Treinar o modelo

```
[38] # Importar a função Auto Arima
     from pmdarima.arima import auto_arima

     # Criando a função do auto_Arima
     Funcao_Auto_Arima = auto_arima(
         # Dados para treinar o modelo
         Base_Feminicídio['Quantidade'],
         # Periodo de inicio
         start_p=1, start_q=1,
         # Maior valor para o periodo de inicio
         max_p=6, max_q=6,
         # período para diferenciação sazonal
         m=12,
         # ordem da parte autorregressiva do modelo sazonal
         start_P=0,
         # Periodo Sacional
         seasonal=True,
         # ordem da primeira diferença
         d=1,
         # ordem da diferenciação sazonal
         D=1,
         # Visualizar a saida serie
         trace=True,
         # ignorar erros
         error_action='ignore',
         # Buscar o melhor de forma rapida
         # Se utilizar como False - será utilizando força bruta no modelo
         # Normalmente como False se tem resultados melhor
         stepwise=True
     )
```

```
Performing stepwise search to minimize aic
 ARIMA(1,1,1)(0,1,1)[12]             : AIC=inf, Time=0.35 sec
 ARIMA(0,1,0)(0,1,0)[12]             : AIC=225.728, Time=0.02 sec
 ARIMA(1,1,0)(1,1,0)[12]             : AIC=207.429, Time=0.09 sec
 ARIMA(0,1,1)(0,1,1)[12]             : AIC=inf, Time=0.20 sec
 ARIMA(1,1,0)(0,1,0)[12]             : AIC=216.636, Time=0.03 sec
 ARIMA(1,1,0)(2,1,0)[12]             : AIC=209.039, Time=0.34 sec
 ARIMA(1,1,0)(1,1,1)[12]             : AIC=209.038, Time=0.20 sec
 ARIMA(1,1,0)(0,1,1)[12]             : AIC=inf, Time=0.23 sec
 ARIMA(1,1,0)(2,1,1)[12]             : AIC=211.038, Time=0.37 sec
 ARIMA(0,1,0)(1,1,0)[12]             : AIC=219.805, Time=0.06 sec
 ARIMA(2,1,0)(1,1,0)[12]             : AIC=204.516, Time=0.15 sec
 ARIMA(2,1,0)(0,1,0)[12]             : AIC=211.763, Time=0.05 sec
 ARIMA(2,1,0)(2,1,0)[12]             : AIC=205.610, Time=0.45 sec
 ARIMA(2,1,0)(1,1,1)[12]             : AIC=205.593, Time=0.34 sec
 ARIMA(2,1,0)(0,1,1)[12]             : AIC=inf, Time=0.37 sec
 ARIMA(2,1,0)(2,1,1)[12]             : AIC=inf, Time=1.45 sec
 ARIMA(3,1,0)(1,1,0)[12]             : AIC=205.217, Time=0.14 sec
 ARIMA(2,1,1)(1,1,0)[12]             : AIC=204.860, Time=0.22 sec
 ARIMA(1,1,1)(1,1,0)[12]             : AIC=202.905, Time=0.28 sec
 ARIMA(1,1,1)(0,1,0)[12]             : AIC=208.337, Time=0.10 sec
 ARIMA(1,1,1)(2,1,0)[12]             : AIC=204.260, Time=0.80 sec
 ARIMA(1,1,1)(1,1,1)[12]             : AIC=204.260, Time=0.50 sec
 ARIMA(1,1,1)(2,1,1)[12]             : AIC=206.260, Time=0.86 sec
```

Vamos fazer os testes

```
# Verificando a melhor performance do modelo
print( Funcao_Auto_Arima.aic() )
```

```
201.90105185979257
```

```
# Definindo o tamanho da base de dados para treino
Tamanho = int(len(Base_Feminicídio) * 0.75)

# Separando os dados de Treino e Testes
Dados_Treino, Dados_Teste = Base_Feminicídio['Quantidade'][0:Tamanho], Base_Feminicídio['Quantidade'][Tamanho:]
```

```
# Treinando o Modelo com os dados de treino
Funcao_Auto_Arima.fit( Dados_Treino )
```

```
ARIMA(maxiter=50, method='lbfgs', order=(0, 1, 1), out_of_sample_size=0,
      scoring='mse', scoring_args={}, seasonal_order=(1, 1, 0, 12),
      start_params=None, suppress_warnings=True, trend=None,
      with_intercept=False)
```

```
# Fazendo a previsão
Previsao = Funcao_Auto_Arima.predict( n_periods=len(Dados_Teste) )

# Incluindo os dados de previsão em um data frame
Base_Previsao = pd.DataFrame( Previsao, index=Dados_Teste.index, columns=['Previsão'])
```

```
# Unindo os dados real x projetado
Juntando_Bases = pd.concat([Dados_Teste, Base_Previsao], axis=1 )

# Plotando o gráfico
Juntando_Bases.plot();
```

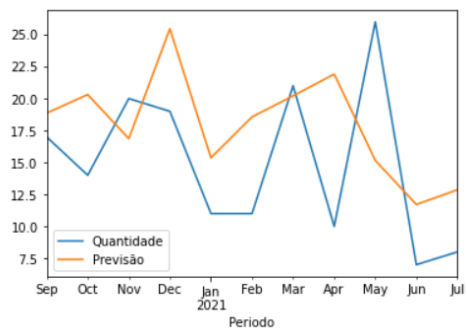


```
# Unindo os dados real x projetado
Juntando_Bases_02 = pd.concat([Base_Feminicídio['Quantidade'], Base_Previsao], axis=1 )

# Plotando o gráfico
Juntando_Bases_02.plot();
```

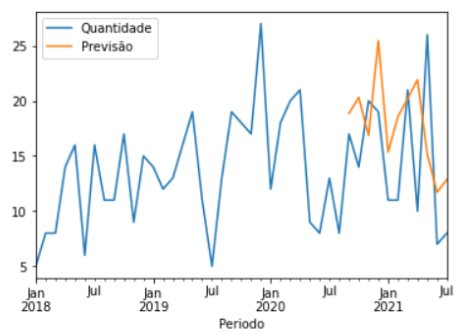


```
# Função para calcular o erro médio quadratico
from sklearn.metrics import mean_squared_error

# Calculando o erro médio do modelo
mean_squared_error(Dados_Teste, Previsao)
```

```
43.359828130831175
```

Vamos prever o próximo semestre

```
[46] # --- Prevendo os próximos meses

     # Treinando o Modelo com os dados de treino
     Funcao_Auto_Arima.fit( Base_Feminicídio['Quantidade'] )
```

```
ARIMA(maxiter=50, method='lbfgs', order=(0, 1, 1), out_of_sample_size=0,
      scoring='mse', scoring_args={}, seasonal_order=(1, 1, 0, 12),
      start_params=None, suppress_warnings=True, trend=None,
      with_intercept=False)
```

```
[47] # Fazendo a previsão até o final do Ano
     Previsao_Final_Ano = Funcao_Auto_Arima.predict( n_periods=6 )
```

```
[48] # Lista para receeber as datas Futuas
     Lista_Datas_Futuras = []

     # Loop para gerar as datas
     for Loop in range(7,13):
       # Somando as datas
       Proxima_Data = Registro_Inicial + relativedelta(month=Loop)

       # Salvando na Lista
       Lista_Datas_Futuras.append( Proxima_Data )
```

```
[49] # Incluindo os dados de previsão em um data frame
     Base_Futura = pd.DataFrame( Previsao_Final_Ano, index=Lista_Datas_Futuras, columns=['Futuro'])
```

```
# Plotar o historio com o realizado
plt.figure( figsize=(15,6) )
plt.title('Projeção de Feminicídio - Estado de São Paulo')
plt.xlabel('Quantidade')
plt.ylabel('Periodo')
plt.plot( Base_Feminicídio['Quantidade'], color='blue' )
plt.plot( Base_Futura, color='red' );
```

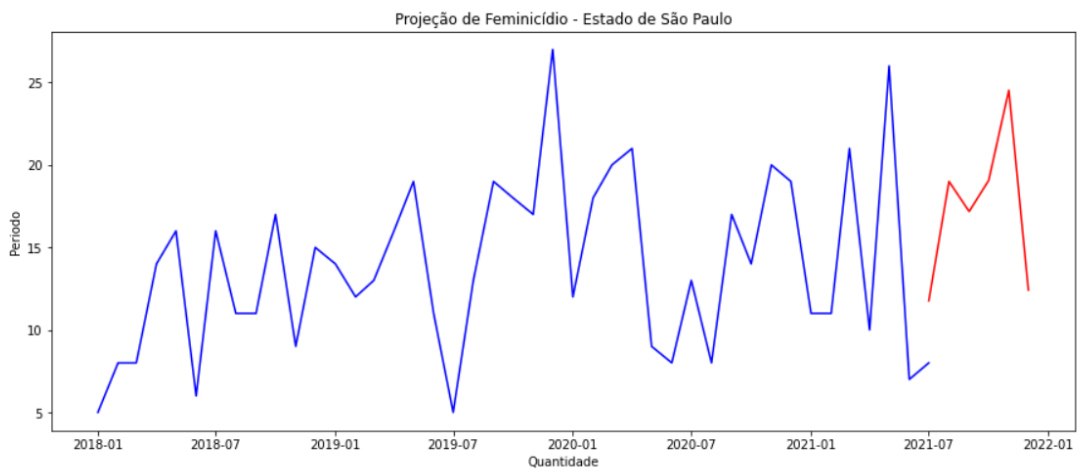

Final

Esse guia foi elaborada para demostrar o uso do Arima

Link do Colab
https://colab.research.google.com/drive/1dij5lTAdVacWSRUwPQtOzbV6X1LcHusy?usp=sharing

Odemir Depieri Jr

Data Intelligence Analyst Sr
Tech Lead
Specialization AI